

Conteúdo

Inteligência Artificial

Luís A. Alexandre

UBI

Ano lectivo 2018-19

Raciocínio Probabilístico
Introdução
Redes Bayesianas
Inferência Aproximada

Amostragem por cadeias de
Markov
Definições de Probabilidades
Leitura recomendada

Conteúdo

Raciocínio Probabilístico
Introdução
Redes Bayesianas
Inferência Aproximada

Amostragem por cadeias de
Markov
Definições de Probabilidades
Leitura recomendada

Introdução

- ▶ Vamos ver como se consegue adquirir conhecimento incerto de forma eficiente.
- ▶ Depois veremos como fazer inferência probabilística de uma forma eficiente.
- ▶ Vamos falar de **redes Bayesianas**.

Introdução

- ▶ Vimos na aula anterior que com a distribuição conjunta de probabilidade podemos responder a qualquer questão sobre o domínio.
- ▶ O problema é que essa distribuição fica muito difícil de obter com o aumento do número de variáveis.
- ▶ Hoje vamos aprender uma nova estrutura de dados: a **rede Bayesiana** (RB), que permite representar a dependência entre variáveis.
- ▶ As RBs permitem representar qualquer distribuição conjunta de probabilidade.

Conteúdo

Raciocínio Probabilístico
Introdução
Redes Bayesianas
Inferência Aproximada

Amostragem por cadeias de Markov
Definições de Probabilidades
Leitura recomendada

Redes Bayesianas

- ▶ Uma RB é um **grafo dirigido** em que cada nodo contém informação probabilística:
 - ▶ Cada nodo corresponde a uma variável aleatória (discreta ou contínua).
 - ▶ Uma aresta do nodo X para o Y significa que X é o pai de Y .
 - ▶ O grafo não contém ciclos.
 - ▶ Cada nodo X_i guarda a distribuição probabilística condicional $P(X_i | Pais(X_i))$ que quantifica os efeitos dos pais no nodo em causa.
- ▶ Quando temos uma aresta a partir de X e a chegar a Y sabemos que X influencia Y .
- ▶ Como as causas estão por detrás dos efeitos, nas RBs, **os nodos causa devem ser pais** dos nodos efeito.

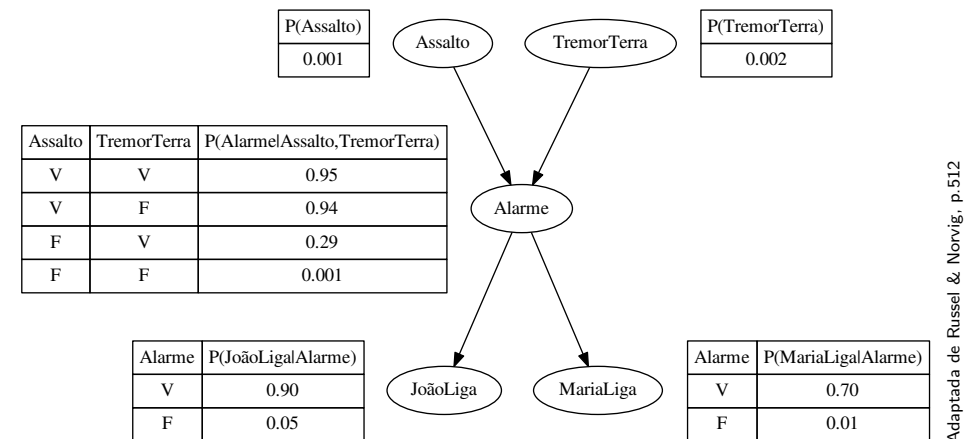
Redes Bayesianas

- ▶ Um perito pode facilmente indicar quais são as causas e os respetivos efeitos: permite construir a topologia da RB.
- ▶ Depois resta determinar as probabilidades condicionais a colocar em cada nodo.
- ▶ Com estes dois elementos, conseguimos achar a distribuição conjunta para todas as variáveis.
- ▶ Se um nodo tem m nodos pai que são variáveis booleanas, então a sua probabilidade condicional pode ser representada numa tabela com 2^m entradas.
- ▶ Nodos que não estão ligados na RB são nodos **condicionalmente independentes**.

Redes Bayesianas: exemplo

- ▶ Vejamos um exemplo: um alarme instalado em casa.
- ▶ Deteta bem assaltantes mas por vezes dispara com tremores de terra.
- ▶ Existem 2 vizinhos, João e a Maria, que prometeram que nos ligavam se o alarme disparasse.
- ▶ O João liga quase sempre quando ouve o alarme mas por vezes confunde o som do telefone a tocar com o do alarme e liga também nesse caso.
- ▶ A Maria ouve música alto e, muitas das vezes, acaba por não ouvir o alarme a tocar.
- ▶ Dada a informação sobre as chamadas recebidas (ou não) dos dois vizinhos, queremos saber qual a probabilidade de existir um assalto.

Redes Bayesianas: exemplo



Redes Bayesianas: exemplo

- ▶ Os nodos *Assalto* e *TremorTerra* só têm associados a probabilidade à priori de ocorrerem visto não dependerem de mais nenhum nodo no nosso problema.
- ▶ Os restantes têm a probabilidade de o respetivo acontecimento ter lugar, face aos acontecimentos de que eles dependem.
- ▶ Exemplo: a probabilidade do alarme tocar dado que não houve assalto e houve um tremor de terra é de 0.29.
- ▶ Os problemas que referimos com o João a confundir o toque do telefone com o toque do alarme e da Maria não ouvir o alarme por causa da música, aparecem condensados nas probabilidades de eles telefonarem dado que o alarme tocou.

Redes Bayesianas: exemplo

- ▶ A probabilidade conjunta será obtida com

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{Pais}(X_i)) \quad (1)$$

onde os x_i representam $X_i = x_i$.

- ▶ Exemplo: achar a probabilidade de o alarme tocar sem ter havido assalto nem tremor de terra e o João e a Maria ligarem a avisar que o alarme tocou:

$$P(\text{JoãoLiga}, \text{MariaLiga}, \text{Alarme}, \neg \text{Assalto}, \neg \text{TremorTerra}) =$$

$$P(\text{JoãoLiga}|\text{Alarme})P(\text{MariaLiga}|\text{Alarme})P(\text{Alarme}|\neg \text{Assalto}, \neg \text{TremorTerra})P(\neg \text{Assalto})P(\neg \text{TremorTerra}) =$$

$$0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998 = 0.000628$$

Construir Redes Bayesianas

- ▶ Vejamos como construir uma RB.
- ▶ **Nodos:** determinar o conjunto de variáveis necessárias para modelar o domínio, $\{X_1, \dots, X_n\}$. Ordenar de modo a que as causas apareçam antes dos efeitos.
- ▶ **Arestas:** Para cada i de 1 a n , fazer:

- ▶ Escolher em $\{X_1, \dots, X_{i-1}\}$ os pais que tornem a seguinte equação válida:

$$P(X_i | X_1, \dots, X_{i-1}) = P(X_i | \text{Pais}(X_i))$$

sendo que $\text{Pais}(X_i) \subset \{X_1, \dots, X_{i-1}\}$.

- ▶ Criar uma aresta entre cada pai e X_i .
- ▶ Escrever a $P(X_i | \text{Pais}(X_i))$.

Construir Redes Bayesianas

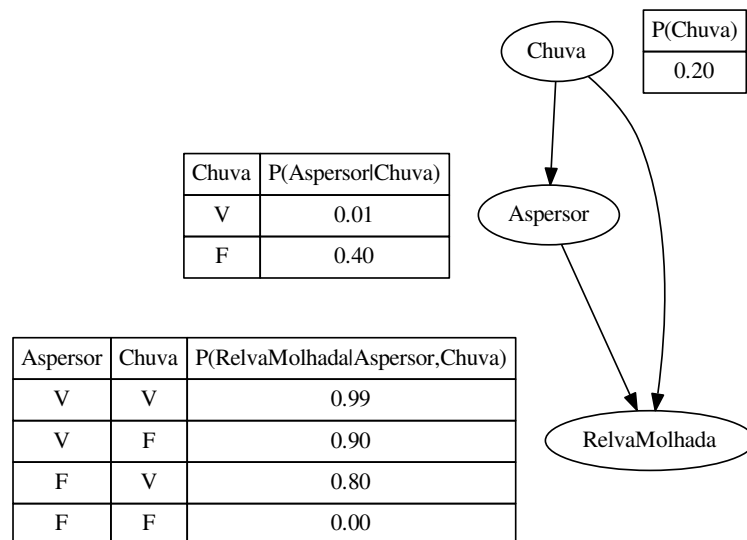
- ▶ Exemplo: imaginemos que faltava colocar o nodo *MariaLiga* na figura acima.
- ▶ Sabemos que este nodo é influenciado por *Assalto* e *TremorTerra*, mas não diretamente, através apenas de *Alarme*.
- ▶ Também sabemos que o *JoãoLiga* não tem influência em *MariaLiga*.
- ▶ Isto traduz-se em

$$P(\text{MariaLiga} | \text{JoãoLiga}, \text{Alarme}, \text{TremorTerra}, \text{Assalto}) = P(\text{MariaLiga} | \text{Alarme})$$

- ▶ Isto implica que *Alarme* é o nodo pai de *MariaLiga*.
- ▶ Uma propriedade importante das RB é que **não têm valores redundantes**, logo não há inconsistências numa RB: nunca são violados os axiomas das probabilidades.

Redes Bayesianas: exercício

- ▶ Dada a seguinte RB, calcule a probabilidade de estar a chover (C) dado que a relva está molhada (R).



Redes Bayesianas: exercício

- ▶ Queremos saber $P(C | R)$.
- ▶ Sabemos que

$$P(C | R) = \frac{P(C, R)}{P(R)}$$

- ▶ Precisamos então de obter $P(C, R)$ e $P(R)$.
- ▶ Da equação (1) sabemos que

$$P(C, A, R) = P(C)P(A | C)P(R | A, C)$$

- ▶ $P(C, R) = \sum_{A \in \{V, F\}} P(C, A, R) = P(C, A, R) + P(C, \neg A, R) =$
 $0.2 \times 0.01 \times 0.99 + 0.2 \times 0.99 \times 0.8 = 0.1604$

Redes Bayesianas: exercício

- ▶ Também sabemos que

$$P(R) = \sum_{A, C \in \{V, F\}} P(R, A, C) =$$

$$P(R, A, C) + P(R, \neg A, C) + P(R, A, \neg C) + P(R, \neg A, \neg C)$$

- ▶ $P(R, A, C) = P(R|A, C)P(A|C)P(C) = 0.99 \times 0.01 \times 0.2 = 0.00198$
- ▶ $P(R, \neg A, C) = P(R|\neg A, C)P(\neg A|C)P(C) = 0.8 \times 0.99 \times 0.2 = 0.1584$
- ▶ $P(R, A, \neg C) = P(R|A, \neg C)P(A|\neg C)P(\neg C) = 0.9 \times 0.4 \times 0.8 = 0.288$
- ▶ $P(R, \neg A, \neg C) = P(R|\neg A, \neg C)P(\neg A|\neg C)P(\neg C) = 0$
- ▶ Temos então $P(R) = 0.44838$.
- ▶ Finalmente, $P(C|R) = 0.1604/0.44838 = 0.3577$.

Conteúdo

Raciocínio Probabilístico
Introdução
Redes Bayesianas
Inferência Aproximada


Amostragem por cadeias de Markov
Definições de Probabilidades
Leitura recomendada

Inferência Aproximada

- ▶ Dado que para casos reais o cálculo da **inferência exata** não é possível devido ao custo computacional, usa-se em geral **inferência aproximada**.
- ▶ Chamam-se **algoritmos de Monte Carlo** a métodos de amostragem aleatória, que fornecem aproximações baseadas na geração de muitas amostras aleatórias.
- ▶ Estamos interessados em algoritmos que permitam estimar probabilidades à posteriori.
- ▶ Vamos ver primeiro um exemplo simples de uso do método de Monte Carlo e depois a inferência baseada em cadeias de Markov.

Método de Monte Carlo

- ▶ Vejamos como usar o método de MC para determinar uma quantidade determinística, o valor de um integral.
- ▶ Consideremos a seguinte função




- ▶ Queremos achar o valor de $I = \int_a^b f(x)dx$.
- ▶ A área do rectângulo tracejado é $A = (b - a) \times f_{\max}$.
- ▶ A probabilidade escolher um ponto ao acaso dentro do retângulo e ele pertencer a zona por baixo da função $f(x)$ é $P = I/A$.

Método de Monte Carlo

- ▶ Podemos determinar P experimentalmente, gerando muitos pontos aleatórios e verificando se estão ou não na área debaixo da curva:
 - ▶ 1- Criar um contador, $c = 0$.
 - ▶ 2- Repetir n vezes os passos 3 a 5:
 - ▶ 3- Escolher 2 valores aleatórios de uma distribuição uniforme entre $[0, 1]$, v_1 e v_2 .
 - ▶ 4- Criar um ponto no retângulo com as coordenadas $x_1 = a + v_1 \times (b - a)$ e $y_1 = v_2 \times f_{max}$.
 - ▶ 5- Se $y_1 \leq f(x_1)$ incrementar o contador c .
 - ▶ 6- A estimativa fica $P = c/n$.
- ▶ Quando tivermos achado P , torna-se imediato achar o valor do integral: $I = P \times A$.

Amostragem de Gibbs

- ▶ Começemos por definir o **lençol de Markov** (LM) de uma variável aleatória: os seus pais, filhos e os outros pais dos seus filhos.



Russel & Norvig, p.518

- ▶ A distribuição de probabilidade de um nodo só depende da distribuição conjunta das variáveis no seu LM.

Amostragem por cadeias de Markov

- ▶ Vejamos então como usar as cadeias de Markov para estimar probabilidades à posteriori, no âmbito das redes Bayesianas.
- ▶ A família de algoritmos de amostragem por cadeias de Markov, normalmente chamados métodos MCMC (Markov Chain Monte Carlo) geram cada nova amostra fazendo uma alteração aleatória na amostra anterior.
- ▶ Há vários algoritmos dentro dos MCMC, mas vamos ver apenas um: a Amostragem de Gibbs.

Amostragem de Gibbs

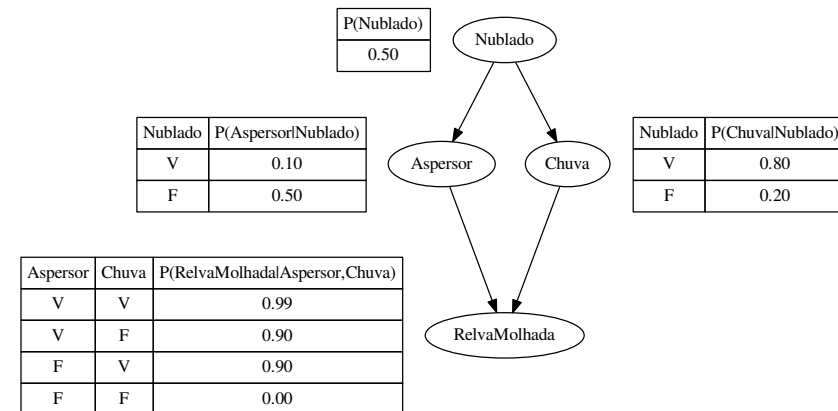
- ▶ Para obtermos uma amostra para X_i vamos levar em conta apenas os valores das variáveis que pertencem ao seu LM.
- ▶ O que a AG faz é:
 - ▶ partir de um estado em que as variáveis observadas têm os seus valores fixos.
 - ▶ gerar um novo estado mudando de forma aleatória o valor das restantes variáveis.
 - ▶ Em cada iteração:
 - ▶ Escolher uma variável X
 - ▶ Calcular $P(X=\text{verdade} \mid \text{as restantes variáveis})$
 - ▶ Atribuir a X ser verdade a probabilidade calculada
 - ▶ Repetir o processo muitas vezes.
 - ▶ A frequência com que uma variável é verdade é a sua probabilidade à posteriori.
 - ▶ Este algoritmo converge para as verdadeiras probabilidades quando esses valores deixam de variar significativamente.

Amostragem de Gibbs

- ▶ Como achar $P(X=\text{verdade} \mid \text{as restantes variáveis})$?
- ▶ Usamos o LM: sabemos que cada variável só depende dos pais, filhos e outros pais dos seus filhos.
- ▶ Então o problema passa a ser achar $P(X=\text{verdade} \mid \text{LM}(X))$.

Amostragem de Gibbs: exemplo

- ▶ Imaginemos que estamos a estimar probabilidades no seguinte problema, e que a ordem topológica das variáveis é definida como $[Nublado, Aspersor, Chuva, RelvaMolhada]$.



Amostragem de Gibbs: exemplo

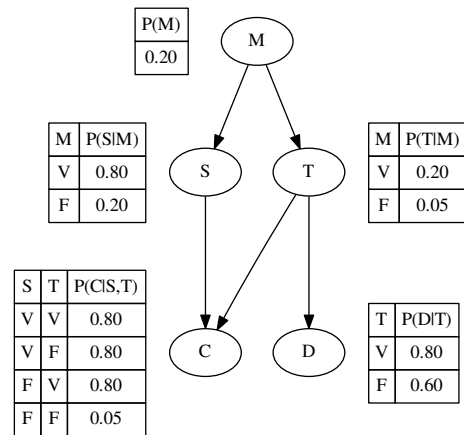
- ▶ Queremos achar $P(\text{Chuva}|\text{Aspersor}, \text{RelvaMolhada})$.
- ▶ Qual é o LM de Chuva?
- ▶ As variáveis Aspersor e RelvaMolhada ficam fixas com os valores que foram observados, ou seja, as variáveis $[\text{Nublado}, \text{Aspersor}, \text{Chuva}, \text{RelvaMolhada}]$ ficam inicialmente com os valores $[?, V, ?, V]$.
- ▶ Depois inicializamos aleatoriamente as restantes variáveis do LM, logo poderíamos obter o estado inicial $[V, V, F, V]$.
- ▶ Agora a AG o que faz é amostrar as variáveis não observadas (Nublado e Chuva), repetidamente.

Amostragem de Gibbs: exemplo

- ▶ Exemplo:
 - ▶ Nublado é amostrado, dados os valores do seu LM, ou seja, $P(\text{Nublado}|\text{Aspersor}, \neg \text{Chuva})$. Se $\text{Nublado} = F$ então o novo estado é $[F, V, F, V]$.
 - ▶ Chuva é amostrado, dados os valores do seu LM, ou seja, $P(\text{Chuva}|\neg \text{Nublado}, \text{Aspersor}, \text{RelvaMolhada})$. Se $\text{Chuva} = V$ então o novo estado é $[F, V, V, V]$.
- ▶ Cada estado visitado durante este processo é uma amostra que permite estimar a questão original sobre a variável Chuva.
- ▶ Se este processo resultar em 20 estados com $\text{Chuva} = V$ e 60 com $\text{Chuva} = F$ então a resposta será que a $P(\text{Chuva}|\text{Aspersor}, \text{RelvaMolhada}) = 0.25$.

RB: exercício

- ▶ O cancro metastático (M) é uma possível causa de tumores no cérebro (T) e também aumenta o cálcio serum (S). Tanto um tumor cerebral como o aumento do cálcio serum podem explicar um coma (C). Sabemos também que os tumores cerebrais podem causar dores de cabeça fortes (D).
- ▶ Represente esta informação numa RB (sem atribuição de probabilidades).
- ▶ Dada a seguinte RB para o problema descrito, ache o valor da probabilidade de um doente ter um tumor cerebral sabendo que tem fortes dores de cabeça.



Adaptado de Bayesian AI, 2nd edition, p.44

- ▶ A **probabilidade conjunta** de n eventos:

$$P(A_1, A_2, \dots, A_n) = \prod_{i=1}^n P(A_i | A_1, \dots, A_{i-1}) \quad (2)$$

- ▶ A **probabilidade conjunta** de n eventos independentes é o produto das suas probabilidades:

$$P(A_1, A_2, \dots, A_n) = \prod_{i=1}^n P(A_i) \quad (3)$$

- ▶ **Probabilidade condicional** relativa a duas variáveis A e B:

$$P(A|B) = \frac{P(A, B)}{P(B)} \quad (4)$$

- ▶ Se Z representa o conjunto de todos os valores das variáveis envolvidas no problema, então podemos obter $P(A)$ **marginalizando**:

$$P(A) = \sum_{B \in Z} P(A, B) \quad (5)$$

- ▶ Se as probabilidades são condicionais em vez de conjuntas (aplicar a equação (4) à anterior):

$$P(A) = \sum_{B \in Z} P(A|B)P(B) \quad (6)$$

- ▶ **Regra de Bayes**

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (7)$$

- ▶ Se duas variáveis A e B são **independentes** então

$$P(A|B) = P(A) \text{ e } P(B|A) = P(B) \text{ e } P(A, B) = P(A)P(B) \quad (8)$$

- ▶ Se duas variáveis A e B são **independentes condicionalmente**, dada a variável C então

$$P(A, B|C) = P(A|C)P(B|C) \quad (9)$$

- ▶ Cada nodo numa RB guarda a seguinte probabilidade condicional:

$$P(A|Pais(A)) \quad (10)$$

- ▶ Numa RB, a **probabilidade conjunta** obtém-se através do produto das distribuições de todos os nodos.

Leitura recomendada

- ▶ Russell e Norvig, cap. 14.