

# Intréligencia Artificial

Luís A. Alexandre

UBI

Ano lectivo 2018-19

Luis A. Alexandre (UBI)

Intréligencia Artificial

Ano lectivo 2018-19

## Conteúdo

### Processamento de Linguagem Natural

#### Introdução

#### Modelos N-grama de símbolos

#### Modelos N-grama de palavras

### Perceção

#### Introdução

#### Operações de baixo-nível

#### Aplicações

#### Leitura recomendada

Luis A. Alexandre (UBI)

Intréligencia Artificial

Ano lectivo 2018-19

2 / 35

Processamento de Linguagem Natural

## Conteúdo

### Processamento de Linguagem Natural

#### Introdução

#### Modelos N-grama de símbolos

#### Modelos N-grama de palavras

### Perceção

#### Introdução

#### Operações de baixo-nível

#### Aplicações

#### Leitura recomendada

Luis A. Alexandre (UBI)

Intréligencia Artificial

Ano lectivo 2018-19

3 / 35

Processamento de Linguagem Natural

Introdução

## Introdução

- ▶ Julga-se que o homem “aprendeu” a falar à cerca de 100 mil anos e a escrever à cerca de 7 mil anos.
- ▶ Existem outros animais que usam linguagens com centenas de símbolos, p.ex., os chimpanzés e os golfinhos.
- ▶ No entanto somos os únicos que conseguem comunicar um número ilimitado de conceitos.
- ▶ O teste de Turing era em grande parte baseado na linguagem exatamente por esta ser tão distintamente um sinal de inteligência.
- ▶ No âmbito da IA existem dois motivos para que seja importante um agente conseguir lidar com a **linguagem natural (LN)**:
  - ▶ para poder interagir facilmente com humanos
  - ▶ para poder adquirir conhecimento a partir de textos escritos.

Luis A. Alexandre (UBI)

Intréligencia Artificial

Ano lectivo 2018-19

4 / 35

Processamento de Linguagem Natural

Introdução

## Modelos de linguagem

- ▶ Para que um agente consiga extrair conhecimento de texto necessita de ter um **modelo da linguagem**: permite a previsão da distribuição de probabilidade das expressões da linguagem.
- ▶ As linguagens formais, como as que usamos em programação, têm modelos precisos.
- ▶ Uma linguagem pode-se definir como um conjunto de strings.
- ▶ Exemplos de strings válidas em Python: “print a” ou “for i in range(10):”.
- ▶ Mas na realidade existe um número infinito de strings e só algumas formam instruções válidas: a **gramática** define as regras de construção de afirmações válidas numa dada linguagem.
- ▶ As linguagens formais têm também um conjunto de regras para definir o significado ou a **semântica** das afirmações.
- ▶ Exemplo: o significado de “2 + 2” é 4 e o de “1 / 0” é um erro.

Luis A. Alexandre (UBI)

Intréligencia Artificial

Ano lectivo 2018-19

5 / 35

Processamento de Linguagem Natural

Introdução

## Modelos de linguagem

- ▶ As LNs não possuem um conjunto bem definido de frases.
- ▶ Há afirmações que são ambíguas, e que por vezes conseguimos perceber o seu significado embora possamos considerar que não seguem as regras e que estão “mal escritas”. Ex.: “Vamos ontem ao teatro e gostámos.”
- ▶ Como as LNs não são rígidas temos que definir um modelo para uma linguagem natural como uma **distribuição de probabilidade sobre as frases**.
- ▶ Em vez de perguntarmos se uma frase faz parte da linguagem perguntarmos qual é a probabilidade da frase fazer parte da linguagem.

Luis A. Alexandre (UBI)

Intréligencia Artificial

Ano lectivo 2018-19

6 / 35

## Modelos de linguagem

- Outra características das LNs é que são **ambíguas**: uma dada afirmação pode ter mais que um significado. Ex.: "Eu gosto deste banco."



- Assim podemos dizer também que o **significado** de uma frase é dado por uma **distribuição de probabilidade** dos **possíveis** significados.
- Outros aspectos das LNs é serem muito **grandes** e estarem em constante **mudança**, o que implica que todos os modelos que usamos acabem por ser apenas **aproximações**.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

7 / 35

## Modelos N-grama de símbolos

- O elemento mais básico duma linguagem é o símbolo ou caráter: letras, números, pontuação e espaços (nas linguagens ocidentais).
- Um dos modelos de linguagem mais simples é uma distribuição de probabilidade sobre uma sequência de símbolos.
- Escrevemos  $P(c_{1:N})$  para representar a probabilidade duma sequência de símbolos de  $c_1$  a  $c_N$ .
- Chamamos a uma sequência de comprimento  $n$  um  $n$ -grama, sendo um unígrafo apenas um símbolo, um bigrama 2 símbolos e um trígrafo 3 símbolos.
- Um modelo de probabilidade de sequências de  $n$  símbolos é um **modelo n-grama**.
- Exemplo:  $P(\text{"the"})=0.027$  e  $P(\text{"zgq"})=0.000000002$ , sendo que estas probabilidades foram estimadas a partir de uma coleção de textos da web.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

9 / 35

## Modelos N-grama de símbolos

- Podemos usar estes modelos, p.ex., para **identificarmos uma dada linguagem**: dado um texto, dizemos em que língua está escrito.
- Os modelos existentes conseguem fazer isto muito bem, mesmo para pequenas frases com 2 ou 3 palavras. Ex.: Google translate

- O que procuramos é estimar as probabilidades:  $P(\text{Língua}_i | \text{Texto})$  para várias línguas possíveis e depois escolhemos aquela que tiver maior probabilidade.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

11 / 35

## Conteúdo

### Processamento de Linguagem Natural

#### Introdução

#### Modelos N-grama de símbolos

#### Modelos N-grama de palavras

Perceção  
Introdução  
Operações de baixo-nível  
Aplicações  
Leitura recomendada

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

8 / 35

## Modelos N-grama de símbolos

- Na realidade um modelo n-grama é uma **cadeia de Markov** de ordem  $n - 1$ .
- Isto significa que a probabilidade do símbolo  $c_i$  só depende dos  $n - 1$  símbolos que o precedem.
- Ex.: no modelo trígrafo (uma cadeia de Markov de ordem 2) temos:

$$P(c_i | c_{1:i-1}) = P(c_i | c_{i-2:i-1})$$

- Podemos definir a probabilidade de uma sequência de símbolos  $P(c_{1:N})$  no modelo trígrafo da seguinte forma:

$$P(c_{1:N}) = \prod_{i=1}^N P(c_i | c_{1:i-1}) = \prod_{i=1}^N P(c_i | c_{i-2:i-1}) \quad (1)$$

- Para um modelo trígrafo duma linguagem com 100 símbolos, existem um milhão de parcelas nesta soma, que podem ser estimadas com um conjunto de textos (**corpus**) de pelo menos 10 milhões de símbolos.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

10 / 35

## Modelos N-grama de símbolos

- Podemos usar a regra de Bayes e o modelo trígrafo obter estas estimativas:

$$\begin{aligned} P(\text{Língua}_i | \text{Texto}) &= \frac{P(\text{Texto} | \text{Língua}_i)P(\text{Língua}_i)}{P(\text{Texto})} \\ &= \frac{P(\text{Língua}_i) \prod_{i=1}^N P(c_i | c_{i-2:i-1}, \text{Língua}_i)}{P(\text{Texto})} \end{aligned} \quad (2)$$

- Como queremos escolher a  $\text{Língua}_i$  mais provável e todos os termos vão ter o mesmo denominador, podemos ignorá-lo.
- Só precisamos então de ter ideia da probabilidade à priori de cada  $\text{Língua}_i$  e estamos a usar um modelo MAP para estimar qual a língua em que o texto está escrito.
- As estimativas da probabilidade à priori duma linguagem dependem do local de onde obtivemos os textos. Na web, sabemos p.ex. que o inglês é muito mais frequente que o português ou o francês.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

12 / 35

## Modelos N-grama de símbolos

- ▶ Podemos usar estes modelos para outras tarefas:
  - ▶ correção de erros em editores de texto
  - ▶ classificação do tipo de texto: romance, poesia, jornalístico, etc.
  - ▶ reconhecer nomes-entidades: procurar num texto nomes de coisas e decidir a que tipo de entidade pertencem. Ex.: "A Ana vai tomar aspirina". Nomes: Ana, aspirina; entidades: pessoa, medicamentos.

## Modelos N-grama de símbolos

- ▶ Duas questões que ocorrem com estes modelos:
  - ▶ algumas sequências de símbolos podem ser muito pouco comuns e não aparecerem no corpus que estamos a usar para estimar as probabilidades. Ficam com probabilidade zero mas na realidade podem ocorrer. Como resolver isto? Fazendo **amaciamento** das probabilidades. A forma mais simples é dizer que para os símbolos  $x$  nunca vistos em corpus com  $n$  símbolos, temos  $P(x) = 1/(n+2)$
  - ▶ como escolher que modelo devemos usar: unígrama, bigrama, trigrama, etc.? Podemos fazer testes usando validação cruzada e escolher aquele que para a tarefa obtenha melhores resultados.

## Conteúdo

**Processamento de Linguagem Natural**  
Introdução  
Modelos N-grama de símbolos  
Modelos N-grama de palavras

Perceção  
Introdução  
Operações de baixo-nível  
Aplicações  
Leitura recomendada

## Modelos N-grama de palavras

- ▶ As ideias que vimos no caso dos modelos para símbolos aplicam-se também no caso dos modelos para palavras.
- ▶ A grande diferença é o que o número de palavras é muito maior que o de símbolos: o **vocabulário** é maior.
- ▶ No caso dos caracteres isolados que vimos antes, podemos usar modelos com um vocabulário de ainda menos que 100 caracteres considerando p.ex. que as letras maiúsculas e minúsculas são equivalentes.
- ▶ Para o português precisaríamos de considerar: 26 letras, 10 dígitos e uns 20 símbolos matemáticos e de pontuação, ou seja, um vocabulário com 56 símbolos no total.
- ▶ Mas a língua portuguesa tem mais de 100 mil palavras.

## Modelos N-grama de palavras

- ▶ Desta forma, um dos problemas que os modelos N-grama de palavras têm de resolver é o das **palavras fora do vocabulário**.
- ▶ Nos modelos para caracteres não precisávamos de nos preocupar com o aparecimento de **símbolos que não existissem no corpus de treino** (a não ser que este fosse muito pequeno) mas com as palavras este é um problema muito presente.
- ▶ Uma forma de resolver isto é considerarmos uma palavra especial UNK que representa o desconhecimento (unknown).
- ▶ Estimamos a probabilidade desta palavra especial da seguinte forma:
  - ▶ ao percorrermos o corpus de **treino**, a primeira ocorrência de **qualquer** palavra é substituída por UNK;
  - ▶ as restantes ocorrências das palavras não são alteradas;
  - ▶ no final, estimamos a probabilidade do símbolo UNK como se ele fosse uma palavra como as outras.
- ▶ Depois, quando uma palavra desconhecida aparece no corpus de **teste**, olhamos para a probabilidade de UNK.

## Modelos N-grama de palavras

- ▶ Exemplo: construiram-se modelos N-grama de palavras usando o texto do livro do Russell e Norvig como corpus.
- ▶ Podemos gerar frases com base nas probabilidades das palavras obtidas em cada um dos modelos:
  - ▶ Unígrama: logical are as are confusion a may right tries agent goal the was ...
  - ▶ Bigrama: systems are very similar computational approach would be represented ...
  - ▶ Trígrama: planning and scheduling are integrated the success of naive bayes model is ...
- ▶ Concluímos que os modelos trigrama já permitem gerar frases muito parecidas com as reais da linguagem, ao passo que os unígrama ficam ainda bastante distantes.

## Modelos N-grama de palavras

- ▶ Estes modelos são usados para tarefas de **classificação** de texto:
  - ▶ deteção de spam: frase com "relógios baratos" ou "comprar Viagra" são provavelmente parte de mensagens de spam ao passo que "queres vir amanhã também?" ou "o prazo de entrega do trabalho é" seriam menos prováveis de fazerem parte de uma mensagem de spam.
  - ▶ análise de sentimento: será que as críticas ao filme X são positivas ou negativas?
- ▶ O PLN tem muitas outras aplicações como a extração de conhecimento, p.ex., a partir de posts no tweeter ou de páginas da wikipédia.
- ▶ Outro campo de aplicação importante da aplicação do PLN é da pesquisa de informação, cujo exemplo mais importante é o dos motores de pesquisa da internet.
- ▶ Outros exemplos importantes de aplicações do PLN: tradução automática e reconhecimento de fala.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

19 / 35

## Conteúdo

Processamento de Linguagem  
Natural

Introdução

Modelos N-grama de símbolos

Modelos N-grama de palavras

Perceção

Introdução

Operações de baixo-nível

Aplicações

Leitura recomendada

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

19 / 35

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

20 / 35

Perceção Introdução

## Introdução

- ▶ A **perceção** interpreta os dados recolhidos pelos sensores do agente fornecendo-lhe informação sobre o ambiente.
- ▶ Os sensores podem ser de muitos tipos, desde um simples interruptor até uma câmara 3D, passando por sensores de ondas rádio, microfones, GPS ou infravermelhos.
- ▶ Nalguns casos os robots fazem **active sensing**: enviam um sinal para o ambiente e recolhem os resultados. Ex.: radar, ultrassons.
- ▶ Nesta parte da aula vamos focar apenas uma modalidade: a visão.



Luís A. Alexandre (UBI)

Inteligência Artificial

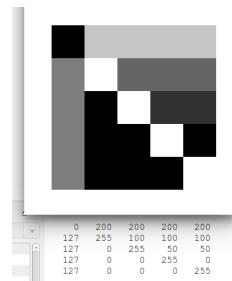
Ano lectivo 2018-19

21 / 35

Perceção Introdução

## Imagen digital

- ▶ Uma característica das imagens é a quantidade de dados que contêm.
- ▶ Uma imagem HD com 1920x1080 pixels, a cores, ocupa cerca de 6MB. São 6 milhões de valores a processar!
- ▶ Deste modo um dos principais aspetos da visão artificial é o de perceber quais os dados que são úteis e quais se podem descartar.



Luís A. Alexandre (UBI)

Inteligência Artificial

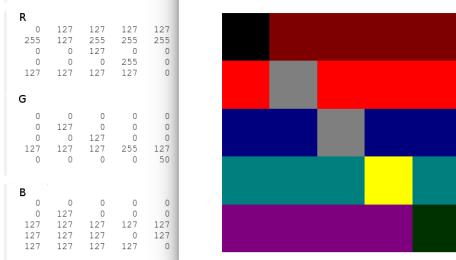
Ano lectivo 2018-19

22 / 35

Perceção Introdução

## Imagen digital

- ▶ Se forem a cores podemos usar uma matriz para cada canal de cor, tipicamente o R, G e B, sendo que cada matriz continua a ter valores inteiros entre 0 e 255.



Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

23 / 35

Perceção Introdução

## Imagen digital

- ▶ Esta gama de valores vem da resolução da câmara: neste caso dizemos que a cor é amostrada a 8 bits (8 bits permitem 256 valores distintos).
- ▶ Existem algumas aplicações em que são usadas câmaras com maior resolução, como por exemplo para obter imagens de mamografias ou raios-X, em que se usam câmaras capazes de amostrar a 10, 12 e até 16 bits por píxel.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

24 / 35

## Operações

- As operações a realizar sobre imagens digitais podem ser categorizadas em 3 tipos:
  - nível baixo: as primeiras normalmente a serem executadas. Ex.: remoção de ruído, deteção de arestas, análise de texturas e cálculo do fluxo ótico.
  - nível médio: segmentação, extração de profundidade, deteção e remoção de sombras, etc.
  - nível alto: aspetos da visão que refletem o uso da memória, contexto ou intenções. Ex.: reconhecimento de objetos, de locais ou de faces.

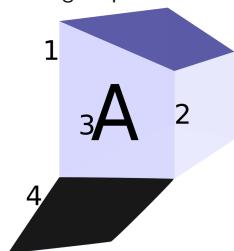
Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19 25 / 35

## Deteção de arestas

- As arestas são uma das características mais importantes numa imagem.
- Podemos ter arestas nas imagens por diferentes motivos:



- descontinuidades na profundidade
- descontinuidades na orientação de superfícies
- descontinuidades nas cores ou tons de zonas da imagem
- descontinuidades na iluminação

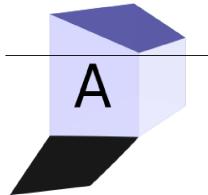
Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19 26 / 35

## Deteção de arestas

- Como acabámos de ver, as arestas aparecem como descontinuidades (de diversos tipos).
- Então para as detetarmos numa imagem temos que procurar detetar descontinuidades.



- Podemos fazê-lo procurando alterações súbitas nos valores de intensidade dos píxeis.
- Uma forma de encontrar estas alterações é usando uma simples diferença entre os valores de intensidade de píxeis consecutivos.
- Para uma dada linha usamos:  

$$d(i) = I(\text{linha}, i + 1) - I(\text{linha}, i)$$

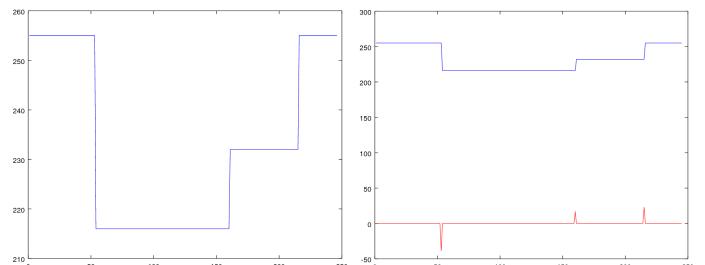
Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19 27 / 35

## Deteção de arestas

- Esquerda: sinal,  $I(\text{linha}, :)$ , da linha marcada na figura anterior.
- Direita: o mesmo sinal mais a diferença entre píxeis consecutivos,  $d(i)$ : deteta as descontinuidades.



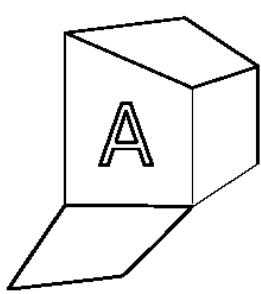
Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19 28 / 35

## Deteção de arestas

- Se repetirmos o processo para todas as linhas e marcaremos as posições de descontinuidade a preto e o resto a branco obtemos isto:



- Exemplo de aplicação a uma imagem real (Lena):

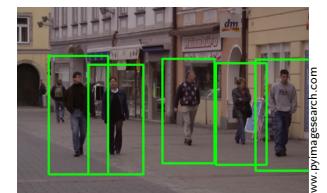
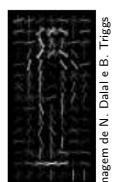


Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19 29 / 35

## Aplicação da deteção de arestas



Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19 30 / 35

## Análise de textura

- A **textura** duma imagem é o **padrão espacial repetido** que esta apresente.



Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

31 / 35

## Análise de textura

- A textura é também uma propriedade muito importante das imagens, e, ao contrário das arestas que são propriedades de 1 pixel apenas, a textura é propriedade de uma **região** da imagem.
- Há várias forma de calcular a textura de uma imagem. Uma das mais simples são os chamados Linear Binary Patterns (LBP).
- O valor de cada pixel na vizinhança é comparado com o do pixel central e criamos uma máscara com 1 quando esse valor for superior ao central.

<table border="1"> <tr><td>24</td><td>39</td><td>7</td></tr> <tr><td>6</td><td>37</td><td>17</td></tr> <tr><td>51</td><td>42</td><td>30</td></tr> </table>	24	39	7	6	37	17	51	42	30	<table border="1"> <tr><td>0</td><td>1</td><td>0</td></tr> <tr><td>0</td><td>■</td><td>0</td></tr> <tr><td>1</td><td>1</td><td>0</td></tr> </table>	0	1	0	0	■	0	1	1	0	<table border="1"> <tr><td>1</td><td>2</td><td>4</td></tr> <tr><td>8</td><td>■</td><td>16</td></tr> <tr><td>32</td><td>64</td><td>128</td></tr> </table>	1	2	4	8	■	16	32	64	128
24	39	7																											
6	37	17																											
51	42	30																											
0	1	0																											
0	■	0																											
1	1	0																											
1	2	4																											
8	■	16																											
32	64	128																											

- O LBP do pixel central é a soma dos coeficientes do lado direito para os pixels em que a máscara é 1. Temos então:  $LBP = 2+32+64 = 98$ .

Luís A. Alexandre (UBI)

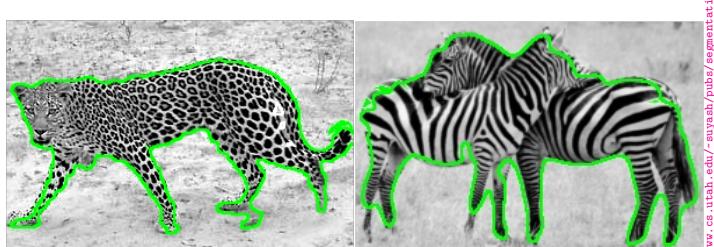
Inteligência Artificial

Ano lectivo 2018-19

32 / 35

## Aplicação da textura

- Podemos usar informação da textura de uma imagem para fazermos segmentação: separar a imagem em regiões.



Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

33 / 35

## Aplicações

- Exemplos de percepção, nomeadamente com imagens, são inúmeros. Vejamos alguns (outros slides e vídeo).

## Leitura recomendada

- Russell e Norvig, sec. 22.1.

Luís A. Alexandre (UBI)

Inteligência Artificial

Ano lectivo 2018-19

35 / 35